upstage Education

최종 제출 워크플로우 설계서

Intelligent Masking | 금융 문서 개인정보 식별·검증·마스킹

팀명	Intelligent Masking
주제	금융 PDF의 서식 분류·필수값 검증·개인정보 위험 등급화와 마스킹본 생성
워크플로우 이름	등급화_V3 검증(#13) / 결합 문서 처리 / 마스킹-중·하
유즈케이스 번호	없음
카드에서 바꾼 점	자체 업무 기획. 최종 데이터셋 32개 PDF, 5개 유형으로 구성.

1. 다룰 업무와 문서 선정 이유

- 업무: 금융 문서를 공유하기 전에 실제 기재된 개인정보를 식별하고, 필수값 검증을 통과한 문서의 위험 등급을 상·중·하로 판정한다. 보완이 필요하면 누락·추가 확인 안내를 제공하며, 등급에 맞는 마스킹본을 생성한다.
- 문서: FATCA/CRS 확인서, 카드·대출·퇴직연금 신청서, 전자금융·증명 서식 등 20종. 가상·공개 문서 기반의 최종 데이터셋은 32개 PDF이며, 결합본의 서류 종류를 따로 세면 38건이다.
  - ① 단순 11건: 값이 기재된 기본 금융 서식
  - ② 양식·문맥 다양성 3건: 제목·배치가 다른 서식
  - ③ 문서 결합 2건: 한 PDF에 서로 다른 서식 4종씩 결합
  - ④ 저품질 6건: 흐림·기울어짐·무늬가 있는 스캔본
  - ⑤ 예외·함정 10건: 필수값·페이지 누락, 공개 법인정보만 있는 문서 등
- 선정 이유: 고유식별번호·계좌·연락처 등이 표와 여러 페이지에 흩어져 있어 수작업 검토·가림 처리의 누락 위험이 크다. 실제 값과 인쇄 안내·빈칸을 구분하는 것이 핵심이다.
- 판정 기준: 65개 공통 항목의 가중치에 다건 보정·부분 마스킹·정보 조합을 반영해 점수 S를 계산한다. #13 최종 출력 지시는 S≥13 상, 5≤S<13 중, S<5 하다. 필수값 누락·판독 확인은 등급과 구별해 검토 경로로 보낸다.

2. 출력 키와 형식

Studio의 실제 출력 항목과 제출 정답지의 비교 항목은 아래와 같다. 유형표에는 점수·설명 없이 최종 판정값만 기록한다.

키	형식	설명 · 예시
판정 (정답지)	문자열	상·중·하 / 필수값 누락 / 추가 확인 필요 / 지원하지 않는 유형의 문서. cases[].answer의 공통 비교 항목. 결합 PDF는 answer. 문서별에 서식별 판정을 함께 기재한다.
개인정보 위험 등급	상 | 중 | 하	검증 통과 경로의 Instruct 출력. 현재 Studio는 등급·점수·근거를 마크다운 표로 반환한다.
위험 점수 / 판정 근거	숫자 표기 / 문자열	점수는 소수 둘째 자리, 근거는 정보 종류와 적용 요인으로 설명한다. 개인정보 원문·계좌번호 등은 재출력하지 않는다.
판정 / 검토 안내	문자열 / 항목 목록	검토 경로는 판정, 누락 항목, 추가 확인, 보완 안내를 출력한다. 명백한 필수값 누락과 문자 판독 확인을 구분한다.
문서종 / 마스킹본	분류값 / PDF	지원 서식 또는 others로 분류한다. 상은 중·하 목표본, 중은 하 목표본을 제공하고 하는 추가 마스킹 없이 처리한다.

등급 경로의 「개인정보 위험 등급」(상·중·하)과 검토 경로의 「판정」(필수값 누락·추가 확인 필요)은 정답지의 단일 「판정」 값에 대응시켜 비교한다.

© 2026 Upstage Education. All rights reserved. 본 자료의 모든 저작권은 (주)업스테이지에 있으며, 무단 복제·배포·공유를 금합니다

3. 노드 구성과 이유

순서	노드	하는 일 · 이유
1	Parse (결합 문서 처리)	텍스트·스캔 PDF를 읽어 분류와 분할에 사용할 텍스트를 만든다.
2	Classify·Split (결합 문서 처리)	여러 서식이 섞인 입력을 서식별로 나누고 지원 서식 또는 others로 분류한다. 문서별 페이지 범위를 유지한다.
3	Instruct (미지원 경로)	others는 지원하지 않는 유형으로 안내하고 등급화·마스킹으로 넘기지 않는다. 최종 정답의 set12·13·14·32는 미지원으로 지정했다.
4	Parse·Classify (등급화)	문서 한 건을 읽고 20개 서식 중 해당 유형을 판별해 서식별 추출 스키마로 연결한다.
5	Extract (등급화)	65개 공통 항목과 서식별 필수 항목을 추출한다. 빈칸·안내·예시·미선택 항목은 제외하고 실제 0은 유효값으로 구분한다.
6	Validate·Instruct (등급화)	필수값 검증 후 통과 경로는 위험 등급·점수·근거, 검토 경로는 누락·추가 확인·보완 안내를 출력한다. 등급은 실제 추출값의 점수 규칙으로 산정한다.
7	마스킹-중 (중 목표본)	상 등급 문서에서 고유식별·민감·금융·인증 등 상위 위험 항목을 가리는 중 목표 PDF를 생성한다.
8	마스킹-하 (하 목표본)	상·중 등급 문서에서 성명·연락처·주소·거래 신청정보 등을 추가로 가리는 하 목표 PDF를 생성한다.

4. 예외 케이스 처리 방식

예외 상황	처리 방식	출력 값
필수 입력값 누락 (계좌·ID·필수 등록값 등)	서식별 실제 적용 항목만 검사한다. 선택하지 않은 분기·빈 여분 행·외부 증빙 목록 자체를 누락으로 확정하지 않는다.	필수값 누락
판독이 어렵거나 확인이 필요한 값	명백한 누락과 구분해 원본 확인을 안내한다. 없는 번호·값을 추정하거나 다른 문서 값으로 보충하지 않는다.	추가 확인 필요
지원하지 않는 서식·예외 입력	others는 등급과 점수를 만들지 않는다. 미지원 4건(set12·13·14·32)은 사용자 확정 기준을 따른다.	지원하지 않는 유형의 문서
여러 서식이 결합된 PDF	별도 결합 문서 처리 경로에서 문서별로 분할해 각각 판정한다. set15·16은 등급이 나온 문서 중 최고 등급(상)을 파일 판정으로 하고, 문서별 판정은 answer.문서별에 기재했다.	문서별 판정 + 파일 판정(최고 등급)
서명·도장·체크 표시의 불명확성	실제 서명·인감 존재는 위험 평가에서 쓰되, 서명·날인·전용 줄 날짜·일반 체크 표시의 불명확성만으로 필수값 보완을 요구하지 않는다.	누락 오탐 제외

서비스 범위: 문서 개인정보 위험 관리와 보완 안내이며, 은행 심사·가입 자격의 승인 또는 거절을 결정하지 않는다.

© 2026 Upstage Education. All rights reserved. 본 자료의 모든 저작권은 (주)업스테이지에 있으며, 무단 복제·배포·공유를 금합니다